State of Data Brasil

Solução de Engenharia de Dados e Analytics

Tech Challenge — Fase 3

Elaine Hernandes

Isabela Bersan Mariano Pádua

Laura Garcias Barreto Soares dos Santos

Lidiany Christiany da Silva

Outubro/2026

Sumário

1. **Sumário executivo** 3
1.1 Principais achados 3
2. Contexto e base de dados 3
2.1 Como ler os números 3
3. Arquitetura e método 4
4. Análises 5
4.1 Como está estruturado o mercado 5
4.2 Quais perfis são mais valorizados 6
4.3 Diversidade de gênero 6
4.4 Tecnologias com maior adoção 7
4.5 Adoção de IA e seu impacto 8
4.6 Regiões, senioridades e modelos de trabalho 9
4.7 Oportunidades e desafios para investir em dados e IA 10
4.8 Oportunidades 11
4.9 Desafios 11
5. Informes técnicos 12
5.1 Pipeline e consultas 12
5.2 Como os gráficos foram gerados 12
5.3 Decisões metodológicas 13
6. Limitações e verificação 13
7. Fontes 14

1. Sumário executivo

O mercado brasileiro de dados paga mais a cada edição da pesquisa, está mais sênior e já usa IA de forma quase universal. O que ainda não amadureceu é a entrega de IA em escala nas empresas, a equidade de gênero e a retenção de talentos. Para uma instituição financeira, esses três pontos definem onde investir.

1.1 Principais achados

- Salários em alta. A média estimada subiu de R$ 10,4 mil (2023) para R$ 13,1 mil (2025). A fatia acima de R$ 20 mil foi de 10,1% para 17,9%.
- IA e engenharia lideram a remuneração. Engenharia de ML/IA ganha R$ 18,6 mil, com alta de 19% em um ano. Gestão chega a R$ 19,8 mil.
- Gênero. Mulheres são 22,0% da amostra em 2025 (24,4% em 2023) e ganham cerca de 18% menos que os homens. Entre Seniores a diferença passou de −10,9% para −18,6%.
- IA é rotina individual, mas não corporativa. 98,2% usam IA no trabalho e 42,3% têm ferramenta paga pela empresa, mas só 26,5% dos gestores têm projetos de IA generativa em produção com resultado.
- Flexibilidade pesa mais que região. A satisfação no presencial integral é 54,3%, contra 74,6% no remoto; 92,9% dos remotos procurariam outro emprego se a presença integral fosse exigida.
- Setor financeiro. Em 2025 paga R$ 14.445 contra R$ 12.743 dos demais setores (+13,4%) e tem satisfação cerca de 8 pontos maior. Em 2024 essa vantagem salarial não existia (−1,5%).

O que propomos. A Seção 6 detalha uma proposta em cinco frentes: remuneração e carreira, flexibilidade de trabalho, equidade, IA em produção e plataforma de dados. A Seção 7 traz os informes técnicos do pipeline e da geração dos gráficos.

2. Contexto e base de dados

A análise usa as três últimas edições da pesquisa State of Data Brasil, da Data Hackers. Os dados foram tratados em um pipeline na AWS e consultados nas tabelas da camada Gold.

Edição	Ano de coleta	Respondentes
2023-2024	2023	5.293
2024-2025	2024	5.215
2025-2026	2025	3.494
Total		14.002

2.1 Como ler os números

- Salário é estimado pelo ponto médio da faixa salarial informada, em reais por mês, em valores nominais.
- Percentuais usam como base quem respondeu à pergunta; nos de nível, região, modelo de trabalho e satisfação, “Não informado” fica de fora. Perguntas de múltipla escolha não somam 100%.
- Comparações entre grupos usam só grupos com 30 ou mais pessoas, salvo quando o texto indica o tamanho da amostra.

3. Arquitetura e método

Os CSVs das três edições foram enviados ao Amazon S3 e processados por três Jobs do AWS Glue em PySpark: Bronze (CSV para Parquet, nomes padronizados), Silver (harmonização das três edições, tipos, deduplicação e correções) e Gold (agregados por pergunta de negócio). O Glue Data Catalog registra 12 tabelas no banco db_state_of_data, e o Athena executa SQL sobre a Gold, incluindo 24 checagens de validação.

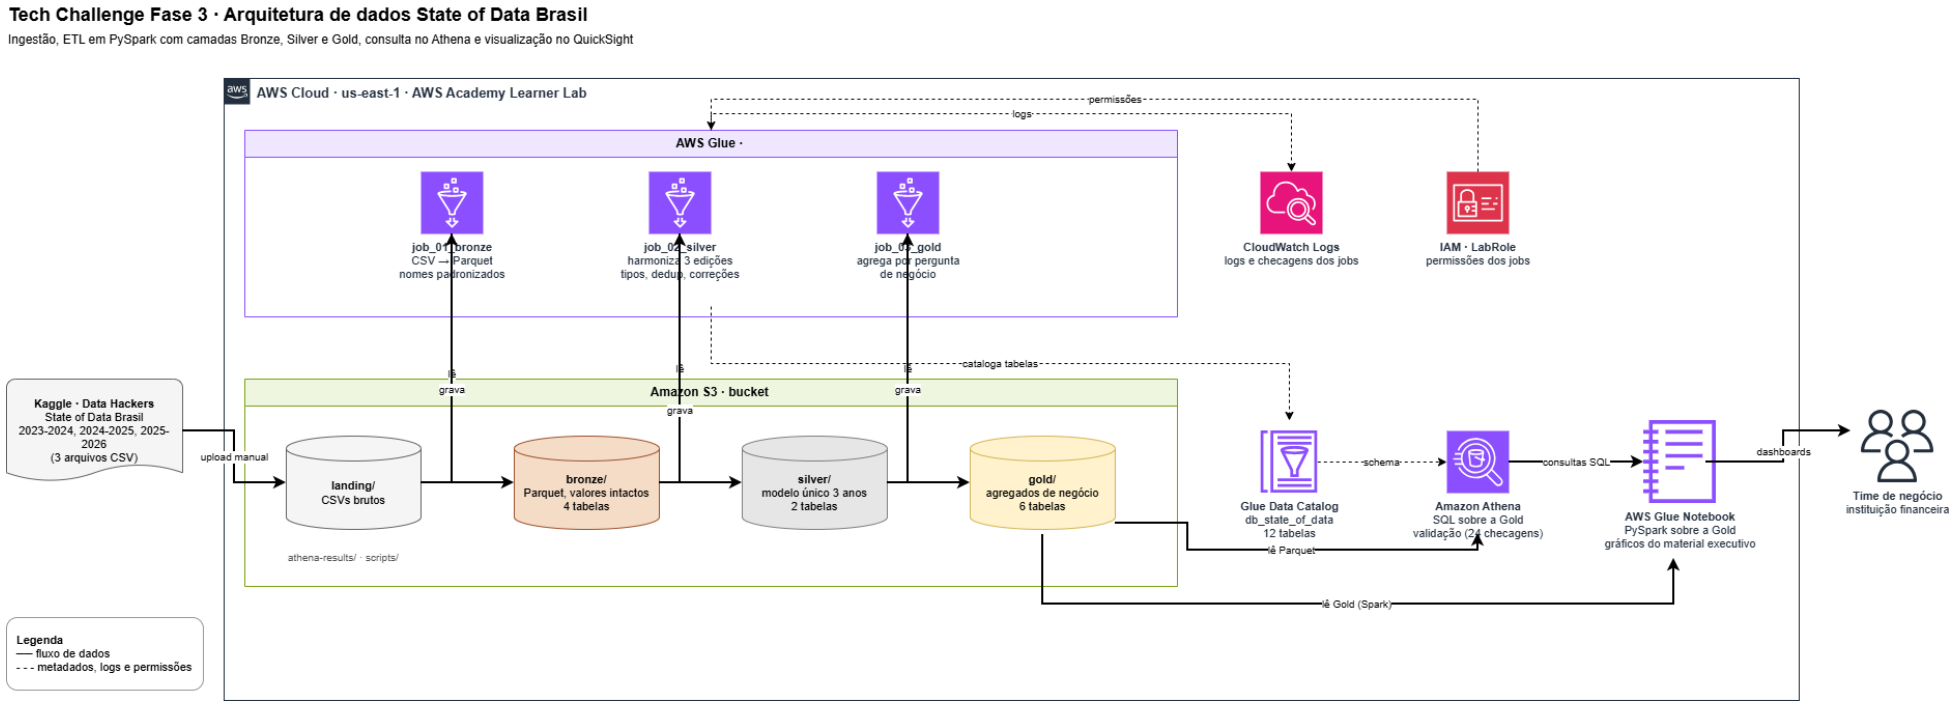


Figura 1. Arquitetura de dados do projeto, do CSV bruto ao material para o time de negócio.

> Gráficos: os oito gráficos deste relatório foram gerados no AWS Glue Notebook (kernel Glue PySpark). O notebook executa as agregações com Spark SQL sobre as tabelas Gold e usa matplotlib para desenhar e salvar as imagens no S3, na pasta graficos/. Os detalhes estão na Seção 7.

4. Análises

Cada subseção responde a uma das sete perguntas de negócio do projeto. Os números vêm das consultas SQL sobre as tabelas Gold, e os gráficos resumem os mesmos números.

4.1 Como está estruturado o mercado

O mercado se concentra em analistas e gestores, em grandes empresas, no setor financeiro e no Sudeste. A fatia de júnior caiu de 22,0% para 16,1% em três anos, enquanto a de gestores cresceu de 16,9% para 20,8% na tabela de indicadores e 22,5% como nível no gráfico.

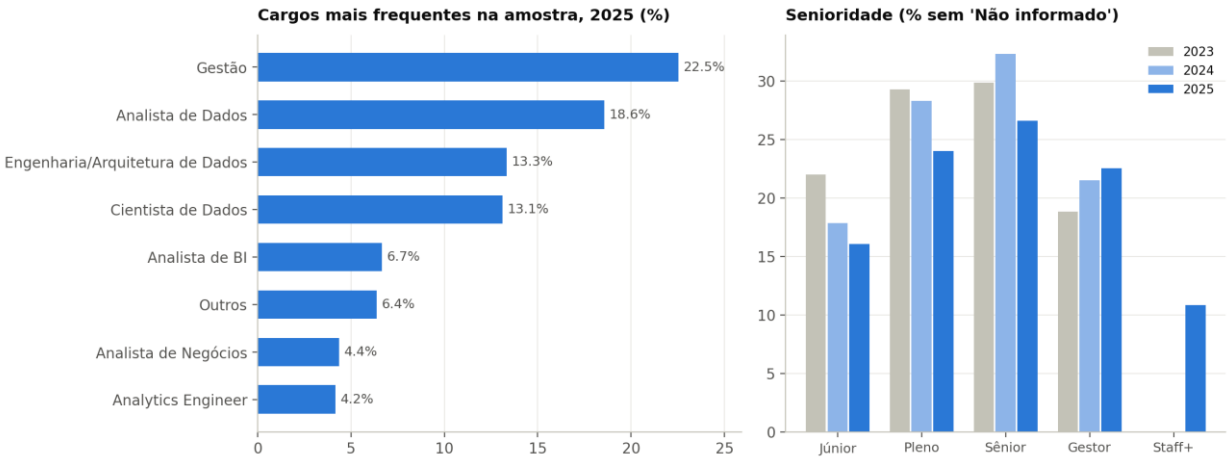


Figura 2. Cargos mais frequentes em 2025 e senioridade de 2023 a 2025, sem "Não informado". Gráfico gerado no Glue Notebook a partir da tabela gold_fato_mercado.

Indicador	2023	2024	2025
Respondentes	5.293	5.215	3.494
Ocupados (%)	90,8	93,8	92,8
Gestores (%)	16,9	20,0	20,8
Júnior (%)	22,0	17,9	16,1
Sênior (%)	29,9	32,3	26,6
Especialista/Staff+ (%)	—	—	10,8
Sudeste (%)	61,4	61,7	64,4
Norte (%)	1,6	1,3	1,4

Na análise das bases, os cargos em 2025 com maior frequência foram: gestão 22,5%, analista de dados 18,6%, engenharia/arquitetura de Dados 13,3%, cientista de dados 13,1% e analista de BI 6,7%. Enquanto os setores nessa mesma análise são: finanças ou bancos 18,5%, tecnologia 17,4% e consultoria 8,8%. Empresas com mais de 3.000 funcionários são a maior faixa nos três anos.

Podemos concluir que o crescimento de gestores e a queda de júnior indicam um mercado que envelhece, o que pressiona a oferta de profissionais experientes. O nível Especialista/Staff+ somente existe a partir de 2025, e parte da queda do Sênior (de 32,3% para 26,6%) vem dessa nova opção.

4.2 Quais perfis são mais valorizados

Senioridade e perfis de IA e engenharia são os mais bem pagos. A média estimada subiu de R$ 10,4 mil em 2023 para R$ 11,9 mil em 2024 e R$ 13,1 mil em 2025, um aumento de cerca de 25% em dois anos.

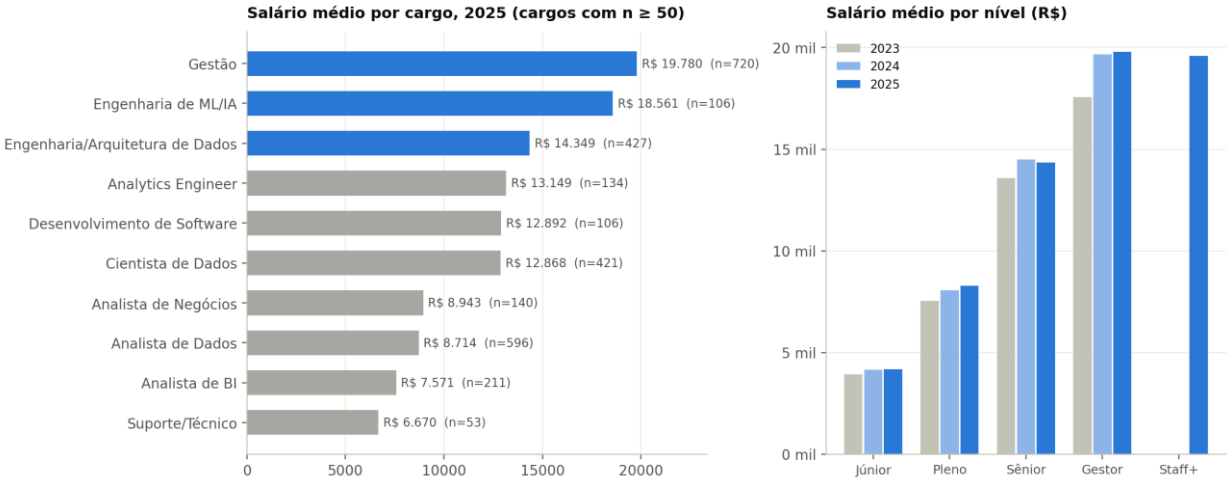


Figura 3. Salário médio por cargo em 2025 e por nível de 2023 a 2025. Gráfico gerado no Glue Notebook a partir da tabela gold_remuneracao.

Nível (R$ por mês)	2023	2024	2025
Júnior	3.923	4.155	4.171
Pleno	7.530	8.050	8.291
Sênior	13.577	14.489	14.335
Especialista/Staff+	—	—	19.603
Gestor	17.569	19.670	19.780

Em 2025, gestão tem média de R$ 19.780 (720 pessoas), engenharia de ML/IA R$ 18.561 (106 pessoas, alta de 19% sobre 2024) e engenharia de dados R$ 14.349 (427 pessoas). O topo da carreira técnica é Staff em engenharia/arquitetura de dados (R$ 22,2 mil) e sênior em engenharia de ML/IA (R$ 21,9 mil). Quem tem até 2 anos de experiência ganha R$ 6,3 mil, e quem tem mais de 10 anos, R$ 21,7 mil.

Conclui-se que o salário quase dobra a cada degrau de senioridade, e o prêmio por IA é o que mais cresce. Para quem contrata, o gargalo está em Sênior e Staff, onde a disputa é maior.

4.3 Diversidade de gênero

As mulheres são 22,0% dos profissionais em 2025, contra 24,4% em 2023, e ganham cerca de 18% menos que os homens. A diferença quase some no Pleno e cresce no Sênior.

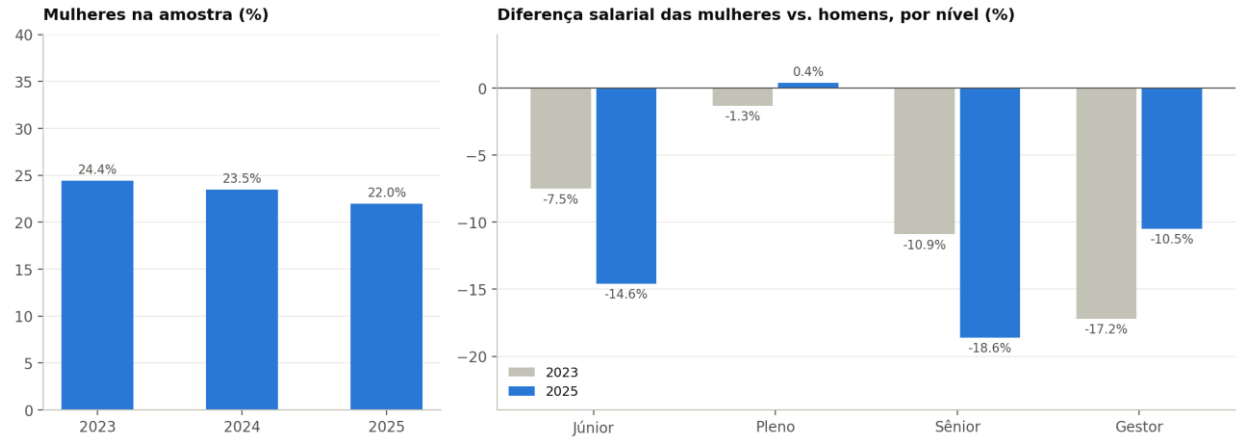


Figura 4. Mulheres na amostra e diferença salarial por nível, 2023 e 2025. Gráfico gerado no Glue Notebook a partir da tabela gold_diversidade_genero.

Indicador	2023	2024	2025
Mulheres na amostra (%)	24,4	23,5	22,0
Diferença salarial geral (%)	−17,8	−18,7	−18,4
Diferença no Júnior (%)	−7,5	+1,6	−14,6
Diferença no Pleno (%)	−1,3	−3,9	+0,4
Diferença no Sênior (%)	−10,9	−16,7	−18,6
Diferença no Gestor (%)	−17,2	−11,9	−10,5

Diferença salarial = salário médio de mulheres em relação ao de homens no mesmo grupo.

A participação feminina cai ao longo da carreira em 2025: júnior 28,2%, pleno 22,3%, sênior 20,8%, Staff+ 20,1% e gestor 18,4%. Por cargo, é maior em Product Manager (42,4%) e analista de negócios (27,7%), e menor em engenharia de ML/IA (15,1%) e engenharia/arquitetura de dados (17,7%).

Uma parcela da diferença geral vem da composição, porque há menos mulheres nos níveis e cargos mais bem pagos. A diferença dentro do sênior, porém, cresceu, e a mistura de cargos pode explicar parte disso, o que estas consultas não testaram. Em Engenharia de ML/IA e Product Manager o número de mulheres é menor.

4.4 Tecnologias com maior adoção

A stack converge para AWS, Python, SQL, Power BI e plataformas como Databricks e PostgreSQL. Databricks foi o que mais cresceu entre 2023 e 2025 (+11,5 pontos percentuais), e Tableau foi o que mais perdeu espaço (−5,3). Databricks também cresce em ferramentas de ETL para análise (+8,6 pp), e SQLite subiu 7,6 pp.

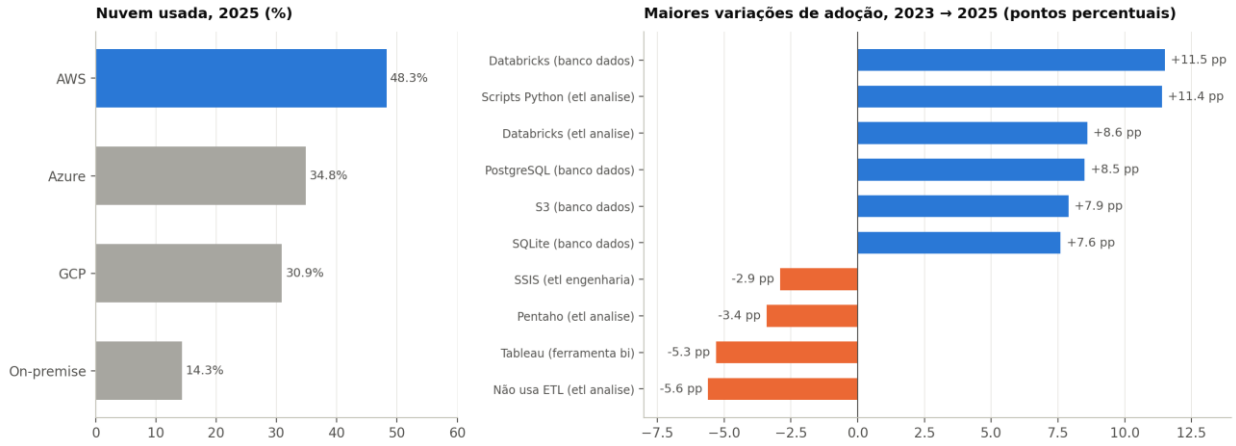


Figura 5. Nuvem usada em 2025 e maiores variações de adoção entre 2023 e 2025. Gráfico gerado no Glue Notebook a partir da tabela gold_adocao_tecnologias.

Tecnologia	Categoria	2023 (%)	2024 (%)	2025 (%)	Variação (pp)
AWS	Cloud	42,3	44,1	48,3	+5,9
Azure	Cloud	31,6	30,9	34,8	+3,3
Google Cloud	Cloud	30,6	29,2	30,9	+0,3
PostgreSQL	Banco/plataforma	28,3	31,4	36,8	+8,5
SQL Server	Banco/plataforma	32,1	29,3	33,5	+1,5
Databricks	Banco/plataforma	21,4	31,1	32,9	+11,5
S3	Banco/plataforma	20,9	23,6	28,8	+7,9
Power BI	BI	57,1	55,2	59,0	+1,9
Looker	BI	23,8	23,0	22,6	−1,2
Tableau	BI	18,9	19,0	13,6	−5,3

Por perfil em 2025, AWS lidera entre engenheiros de dados (58,7%) e de ML/IA (63,2%); entre analistas de BI, a líder é Azure (37,4%). Athena subiu 3,3 pontos (15,2%) e QuickSight 3,1 (6,8%).

4.5 Adoção de IA e seu impacto

O uso individual de IA para produtividade chegou a 98,2% em 2025, contra 81,0% em 2023. Mas só 26,5% dos gestores relatam projetos de IA generativa em produção com resultado.

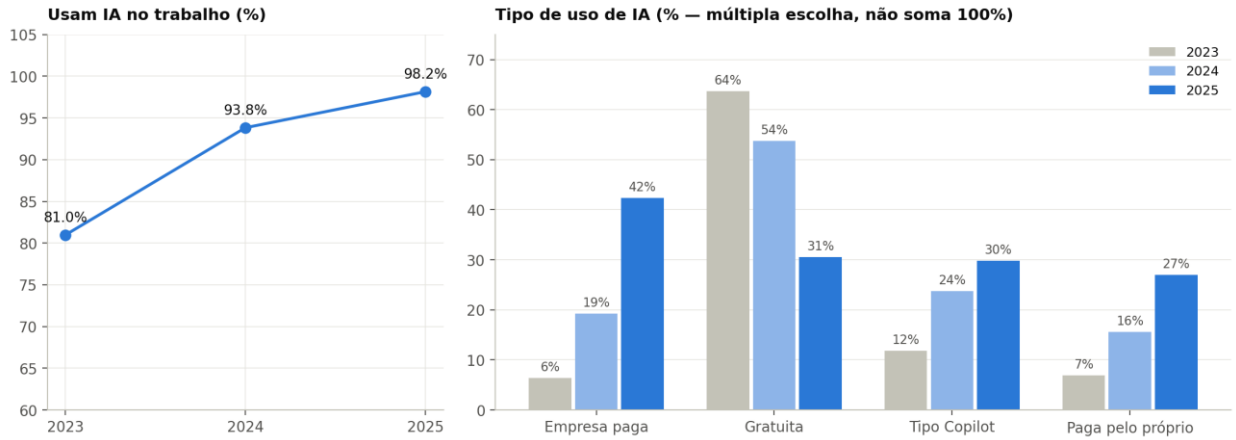


Figura 6. Uso de IA no trabalho e tipo de uso, 2023 a 2025. Gráfico gerado no Glue Notebook a partir da tabela gold_adocao_ia.

Uso de IA para produtividade (%)	2023	2024	2025
Usa alguma IA	81,0	93,8	98,2
A empresa paga a ferramenta	6,4	19,3	42,3
Usa só ferramentas gratuitas	63,7	53,7	30,6
Usa assistente de código (tipo Copilot)	11,8	23,7	29,8
Paga do próprio bolso	6,9	15,5	26,9

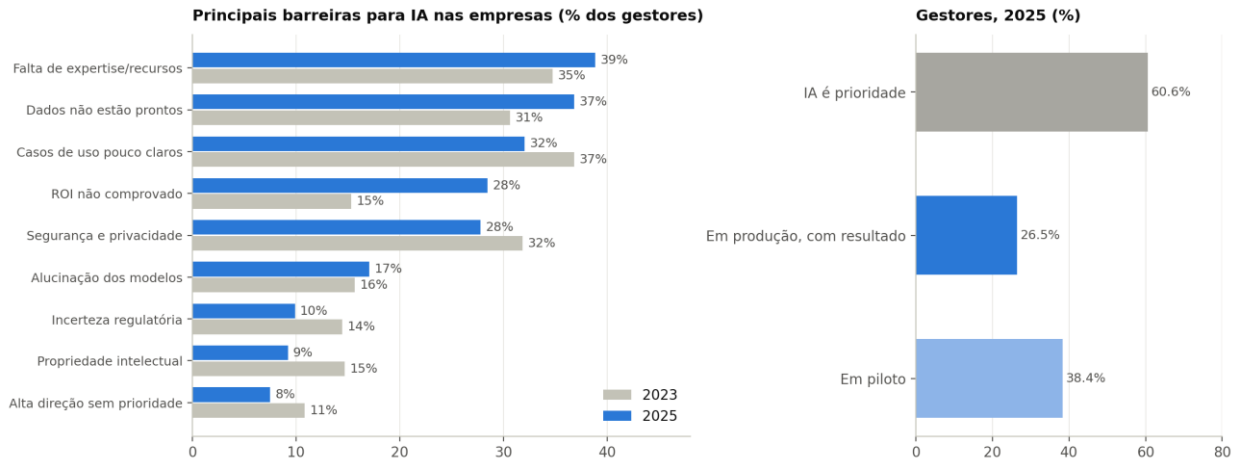


Figura 7. Barreiras à IA (2023 e 2025) e estágio da IA nas empresas, segundo gestores. Gráfico gerado no Glue Notebook.

Entre os gestores em 2025, 60,6% dizem que IA é prioridade (36,2% em 2023). Quanto aos resultados, 26,5% têm projetos em produção, 38,4% estão em pilotos, 15,0% em investigação e 13,5% não começaram. As barreiras mais citadas são falta de expertise ou recursos (38,8%), dados não prontos para IA (36,8%), casos de uso pouco claros (32,0%) e ROI não comprovado (28,5%, contra 15,3% em 2023). O uso com direcionamento centralizado foi de 10,5% para 35,7%. Entre 2023 e 2025, expertise (35% para 39%), dados não prontos (31% para 37%) e ROI (15% para 28%) ganharam peso, enquanto casos de uso pouco claros (37% para 32%) e segurança e privacidade (32% para 28%) perderam.

O impacto no salário para quem usa IA ganha em média R$ 11,4 mil, contra R$ 10,2 mil de quem não usa. É correlação, e não causa, e o grupo que não usa tem só 36 pessoas.

Leitura: a barreira principal é gente e dado, e não ferramenta. A pressão por ROI cresce à medida que os pilotos envelhecem sem chegar à produção.

4.6 Regiões, senioridades e modelos de trabalho

O modelo de trabalho pesa mais que a região. No mesmo nível, os salários regionais ficam próximos, e a satisfação no presencial é cerca de 20 pontos menor que no remoto.

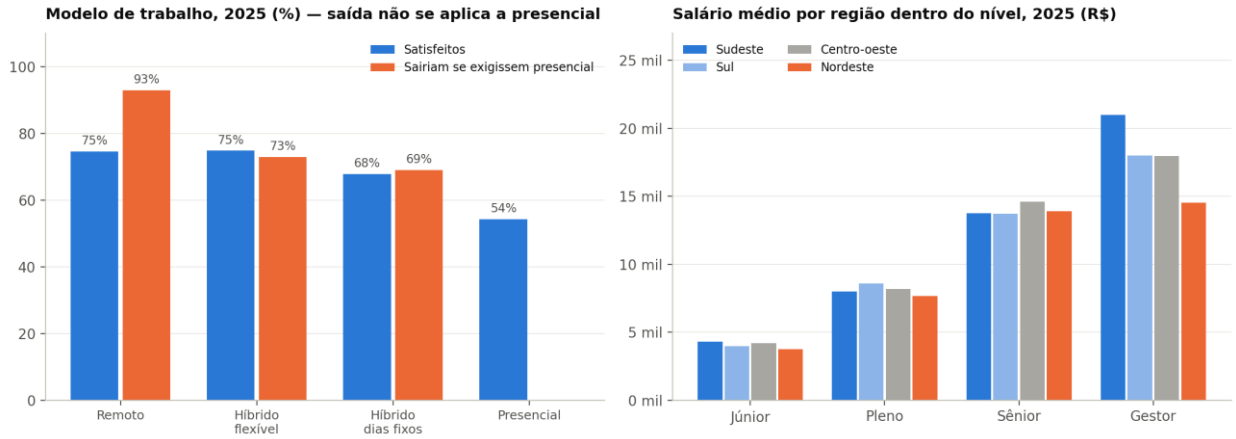


Figura 8. Satisfação e intenção de saída por modelo de trabalho, e salário por região e nível, em 2025. Gráfico gerado no Glue Notebook a partir da tabela gold_trabalho_regiao.

Modelo atual (2025)	Particip. (%)	Salário médio (R$)	Satisfeitos (%)	Sairia se exigissem 100% presencial (%)
Remoto	39,6	14.538	74,6	92,9
Híbrido flexível	19,6	14.684	74,8	72,9
Híbrido com dias fixos	20,1	12.625	67,8	69,0
Presencial	20,7	9.120	54,3	32,1

O remoto caiu de 46,3% em 2023 para 39,6% em 2025, e o presencial subiu de 16,6% para 20,7%. Dos 663 presenciais de 2025, só 39 preferem continuar assim, e 290 preferem híbrido flexível.

Região (2025, R$)	Júnior	Pleno	Sênior
Sudeste	4.298	8.009	13.760
Sul	3.982	8.578	13.739
Centro-oeste	4.192	8.173	14.617
Nordeste	3.758	7.651	13.924

O Norte não aparece porque nenhum nível chega a 30 pessoas.

A diferença regional no salário médio geral vem mais da quantidade de seniores em cada região do que de pagar menos pelo mesmo nível; isso é interpretação a partir da tabela. A exceção é Gestor no Nordeste (R$ 14.539 contra R$ 21.006 no Sudeste, amostra de 63 pessoas).

4.7 Oportunidades e desafios para investir em dados e IA

O setor financeiro já paga e retém melhor. A maior oportunidade é levar IA do piloto à produção, e o maior risco é perder talentos escassos.

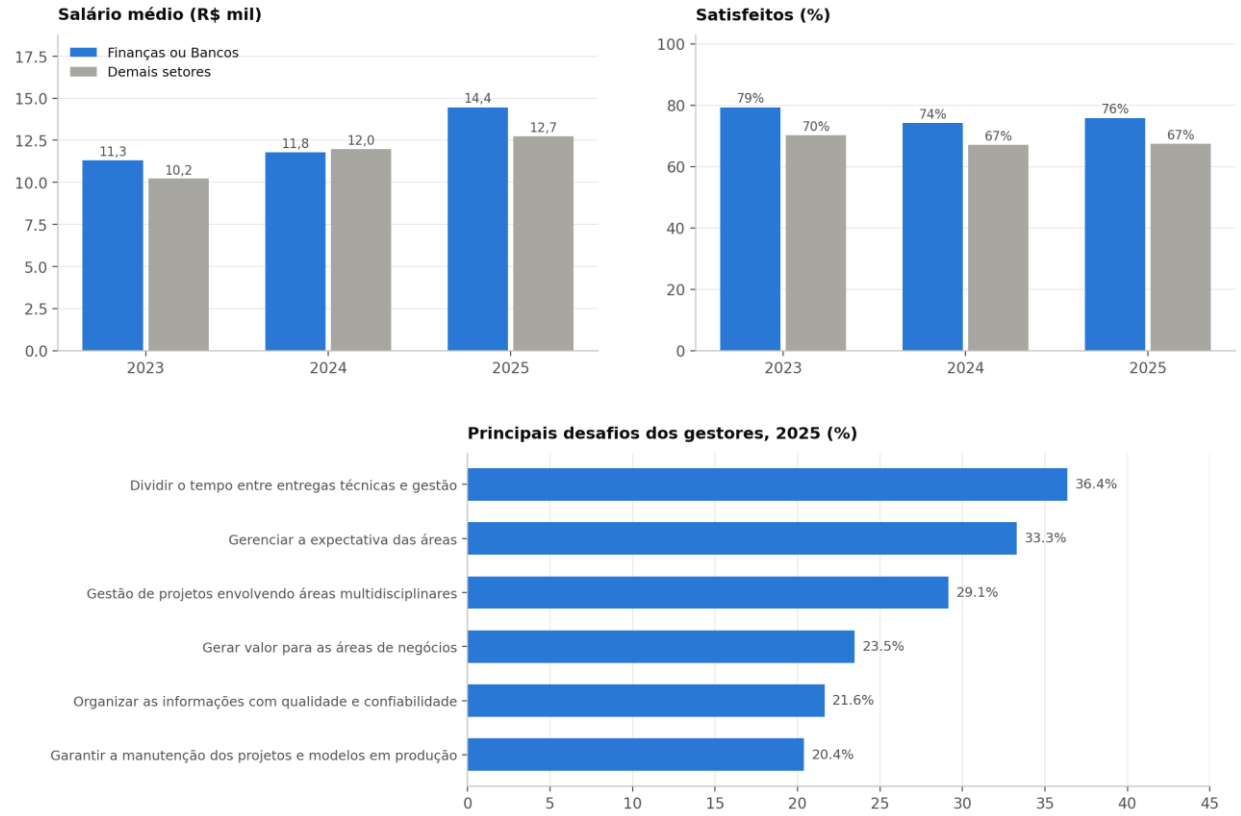


Figura 9. Setor financeiro contra demais setores (salário e satisfação) e desafios dos gestores em 2025. Gráfico gerado no Glue Notebook.

Indicador	Finanças 2023	Demais 2023	Finanças 2025	Demais 2025
Salário médio (R$)	11.310	10.227	14.445	12.743
Satisfeitos (%)	79,2	70,2	75,8	67,4
Usa IA para produtividade (%)	74,8	82,5	98,1	98,2

Satisfação sem os respondentes de nível “Não informado”, que não receberam a pergunta. A tabela de ocupados usada na análise de perguntas de negócio dá 76,1% e 68,1% em 2025; a conclusão (cerca de 8 pontos a favor de finanças) é a mesma.

4.8 Oportunidades

1. Levar IA à produção: só 26,5% das empresas têm IA generativa em produção. As duas maiores barreiras são expertise (38,8%) e dados não prontos (36,8%).
2. Base de dados primeiro: investir em plataforma e qualidade de dados ataca a barreira “dados não prontos”.
3. Stack com mercado amplo: AWS (48,3%), Databricks (32,9%), PostgreSQL (36,8%), Python e Power BI (59,0%) concentram a adoção, o que facilita contratar e capacitar.
4. Ferramentas de IA pagas pela empresa: já são 42,3% em 2025, contra 6,4% em 2023; deixaram de ser diferencial e viraram expectativa.
5. Atração: o setor financeiro paga 13% acima dos demais em 2025 e tem satisfação cerca de 8 pontos maior.

4.9 Desafios

1. Talento de IA escasso e caro: Engenharia de ML/IA ganha R$ 18,6 mil em média, com alta de 19% em um ano.

2. Retenção: 75,2% dos ocupados buscam emprego (34,5%) ou estão abertos a propostas (40,7%). Os critérios mais citados para escolher emprego são salário (83,2%) e trabalho remoto (56,6%).
3. Modelo de trabalho: exigir presença integral levaria 92,9% dos remotos a procurar outro emprego.
4. Diversidade: mulheres são 22,0% e ganham 18,6% menos no nível Sênior; a participação caiu desde 2023.
5. Gestão de dados: os principais desafios dos gestores são dividir tempo entre entregas técnicas e gestão (36,4%, era 29,4% em 2023) e administrar expectativas do negócio (33,3%), seguidos de projetos multidisciplinares (29,1%), gerar valor para o negócio (23,5%) e organizar informações com qualidade (21,6%).

5. Informes técnicos

5.1 Pipeline e consultas

- Armazenamento: Amazon S3, com prefixos landing/, bronze/, silver/, gold/, athena-results/, scripts/, notebooks/ e graficos/.
- Processamento: três Jobs do AWS Glue em PySpark (Bronze, Silver e Gold), com logs no CloudWatch e permissões pela LabRole do AWS Academy Learner Lab (us-east-1).
- Catálogo e consulta: Glue Data Catalog com 12 tabelas no banco db_state_of_data (4 Bronze, 2 Silver e 6 Gold); Amazon Athena para SQL.
- Validação: 24 checagens no Athena sobre contagens e totais das camadas, todas iguais ao esperado. Os números das sete respostas vêm de 32 consultas SQL sobre as tabelas Gold.
- Consultas dos gráficos: arquivos consultas_athena_P1_a_P7.sql e consultas_athena_ajustes.sql, rodados no Athena para validar os números antes do notebook.

5.2 Como os gráficos foram gerados

Os oito gráficos foram gerados no AWS Glue Notebook, aberto no Glue Studio com o kernel Glue PySpark. O notebook segue este fluxo:

1. Configuração da sessão: Glue 5.1, tipo de worker G.1X, 2 workers e encerramento por inatividade de 60 minutos, para controlar o custo no Learner Lab. A biblioteca matplotlib é instalada pela sessão.
2. Agregação em Spark: cada gráfico executa uma consulta com spark.sql sobre as tabelas Gold do catálogo, calculando médias ponderadas e percentuais no cluster.
3. Conversão e desenho: o resultado, que é pequeno, é convertido para pandas, e o matplotlib desenha o gráfico. Colunas numéricas retornadas como Decimal são convertidas para float.
4. Saída: cada gráfico é salvo como PNG na pasta graficos/ do bucket do projeto e usado neste relatório.

Gráfico	Tabela Gold e critério principal
p1_estrutura_mercado	gold_fato_mercado; nível e cargo sem “Não informado”
p2_salarios	gold_remuneracao; média ponderada SUM(soma_salario_estimado) / SUM(qtd_com_salario); cargos com n ≥ 50
p3_diversidade_genero	gold_diversidade_genero; grupos com n ≥ 30

Gráfico	Tabela Gold e critério principal
p4_tecnologias	gold_adocao_tecnologias; categorias de banco de dados, cloud, BI e ETL
p5a_adocao_ia e p5b_ia_nas_empresas	gold_adocao_ia; percentual sobre quem respondeu à pergunta
p6_regiao_modelo	gold_trabalho_regiao; sem “Não informado”
p7_oportunidades_desafios	gold_fato_mercado e gold_adocao_tecnologias; finanças contra demais setores

5.3 Decisões metodológicas

- “Não informado” fora dos percentuais: esses respondentes têm satisfação 0,0 porque a pergunta não foi feita. Incluí-los puxava a satisfação de 2025 de 67,4% para 61,2%.
- Amostra mínima: grupos com menos de 30 pessoas ficam fora dos comparativos; no gráfico de cargos o corte é 50. Em Engenharia de ML/IA e Product Manager o n é pequeno e o texto sinaliza isso.
- Divisão em Athena: a divisão entre inteiros trunca o resultado; as consultas usam 100.0 * para manter casas decimais.
- Diferença de base: a satisfação do setor financeiro na Figura 9 exclui o nível “Não informado”, e a tabela de ocupados da análise de negócio usa outra base; por isso os valores diferem em até 0,7 ponto.

6. Limitações e verificação

Os números são confiáveis para comparar grupos e anos dentro da pesquisa, com as ressalvas abaixo.

- Salário estimado: ponto médio da faixa; a faixa “acima de R$ 40.001” não tem teto e subestima as médias do topo.
- Valores nominais: não há correção pela inflação do período.
- Amostra voluntária: não representa estatisticamente todo o mercado, e a edição 2025 é menor (3.494 respondentes).
- Nível novo em 2025: Especialista/Staff+ afeta a comparação do Sênior entre anos.
- Pergunta de linguagens mudou em 2025: de “usada no dia a dia” para “preferida”.
- Amostras pequenas: Engenharia de ML/IA (106), Product Manager (33) e Gestor no Nordeste (63).
- IA e salário: correlação; o grupo sem IA tem 36 pessoas.

Afirmação	Como foi verificada	Status
Contagens e totais das camadas Bronze, Silver e Gold	24 checagens no Athena, todas iguais ao esperado	Confirmado
Números das sete respostas	32 consultas SQL sobre as tabelas Gold, rodadas localmente	Confirmado localmente
Números dos gráficos	Consultas P1 a P7 e ajustes rodados no Athena e conferidos contra o documento das respostas	Confirmado
Interpretações e proposta	Inferência a partir das tabelas	Interpretação
Inflação do período	Não consultada	Em aberto

7. Fontes

- State of Data Brazil 2024/2025, dataset no Kaggle (Data Hackers): https://www.kaggle.com/datasets/datahackers/state-of-data-brazil-20242025/data
- State of Data 2025-2026, relatório, Bain & Company e Data Hackers, 2025: https://www.bain.com/link/9b0a3b17f0514d3d94866e11b65e9563.aspx
- Download do relatório State of Data Brazil 2025/2026, Data Hackers; coleta de 14/10 a 18/12/2025: https://www.datahackers.news/p/download-do-relatorio-state-of-data-brazil-2025-2026
- Consultas e notebook do projeto: consultas_athena_P1_a_P7.sql, consultas_athena_ajustes.sql, athena_perguntas_negocio.sql e analise_state_of_data.ipynb.